01 Не все ли равно, что думают другие?

> Научное знание — это способность делать либо хорошее, либо плохое, но оно не содержит инструкции по своему использованию.
>
> [...]
>
> *Каждому человеку дан ключ, открывающий врата рая; этот же самый ключ открывает и врата ада.*
>
> Ричард Фейнман. «Ценность науки»
> Отрывок из книги «Не все ли равно, что думают другие?»

Леонард и Шелдон опубликовали статью о новой модели Вселенной. Чтобы следить за реакцией научного сообщества, они решили разработать систему, которая находит новые комментарии об их работе и классифицирует их на положительные и отрицательные.

Леонард собрал выборку комментариев, обучил на ней Word2Vec, представил каждый комментарий в виде среднего арифметического эмбеддингов его слов и обучил поверх полученных представлений логистическую регрессию. На тестовой выборке он получил ROC AUC = 0.53.

За ужином Леонард пожаловался Пенни на результат. Та ответила: «Ну, хотя бы не 0 — уже неплохо!»

1) Согласны ли вы с оценкой Пенни? Ответ обоснуйте.

2) Какие особенности Word2Vec могут мешать анализу тональности текстов (англ. sentiment analysis)?

Пока Леонард и Пенни ужинали, Шелдон решил улучшить модель и переписал код, заменив Word2Vec на TF-IDF.

3) В некотором комментарии слово «невероятная» встречается 3 раза, а слово «работа» — 1 раз. Какое из слов имеет большее значение TF для этого комментария?

4) Слово «работа» встречается во всех 197 комментариях выборки, а слово «невероятная» — в 57. Какое из слов имеет большее значение IDF?

Профессору Хокингу очень понравилась работа. Правда, при написании комментария он случайно допустил опечатку:

> Прееекрасная работа!

5) Какие проблемы может вызвать эта опечатка, если код использует токенизацию на уровне отдельных слов? Как можно повысить устойчивость модели к подобным опечаткам?

02 Простое число Шелдона[1]

Шелдон: Самое замечательное число — 73. Вы, скорее всего, теряетесь в догадках почему.

Леонард и Говард: Нет, нет, и в мыслях не было.

Шелдон: 73 — это 21-е простое число. Его зеркальное отражение 37 является 12-м, чье отражение 21 является результатом умножения, не упадите, 7 и 3. Ну, не обманул?

Леонард: Убедил. Число 73 — Чак Норрис всем числам.

Шелдон: Чак Норрис нервно курит в сторонке. В двоичной системе число 73 записывается как 1001001, а если прочесть наоборот, то получается 1001001. А Чак Норрис наоборот — это всего лишь жалкий Сиррон Кач.

«Теория большого взрыва», сезон 4, серия 10

Шелдон разработал языковую модель, которая генерирует интересные факты. На каждом шаге она выдает скрытое состояние $h \in \mathbb{R}^d$, которое затем проецируется на словарь размера V. Таким образом, логиты модели вычисляются по формуле $z = Wh$.

1) Какой размер имеет матрица проекции W?

2) Что такое связывание весов (англ. weight tying)? В каких случаях оно используется?

Далее с помощью softmax логиты преобразуются в распределение вероятностей, из которого случайным образом выбирается следующий токен:

$$\operatorname{softmax}(z)_i = \frac{e^{z_i}}{\sum_{j=1}^{V} e^{z_j}}.$$

Предположим, что модель присвоила токену t наибольшую вероятность.

3) Что при связывании весов можно сказать о скалярном произведении скрытого состояния h и эмбеддинга токена t?

Говард решил проучить Шелдона за недавние издевки и добавил в код строку, которая прибавляет число 73 ко всем логитам перед вычислением softmax.

4) Как изменится распределение вероятностей при выборе следующего токена? Ответ обоснуйте.

5) Как изменится генерация, если вместо прибавления 73 разделить все логиты на 2.1?

[1] Кстати, вот вам интересный факт: простым числом Шелдона (англ. Sheldon prime) называют такое простое число, у которого произведение цифр в десятичной записи совпадает с порядковым номером в последовательности простых чисел, а переворот цифр дает простое число с перевернутым порядковым номером. Например, 73 — это 21-е простое число, $7 \times 3 = 21$, а 37 — 12-е простое число. В 2019 году Карл Померанс и Крис Спайсер доказали, что 73 — единственное такое число. См.: Pomerance C., Spicer C. *Proof of the Sheldon Conjecture*. The American Mathematical Monthly. 2019. Vol. 126, № 8. P. 688–698.

03 Человек, говорящий на тысяче языков

Говард: Кажется, ты не понимаешь английское слово «нет». Может, другой язык поможет. По-русски: «нет». По-китайски: «бу». По-японски: «иэ». По-клингонски: «ко». В двоичном коде ASCII: 01101110 01100111.

Шелдон: Вообще-то, 0110111…

Говард: Нет!

«Теория большого взрыва», сезон 5, серия 21

В данном задании каждое слово является отдельным токеном. Говард любит изучать иностранные языки. Сейчас он изучает русский язык и решил написать Seq2Seq-модель для перевода EN → RU на основе encoder-decoder Transformer.

На вход encoder подается текст:

> I am not crazy my mom had me tested

1) Как зависит вычислительная сложность self-attention в encoder от длины входной последовательности N?

2) Какой размер имеет матрица весов self-attention в encoder в примере выше?

После нескольких шагов генерации на вход decoder подается следующая последовательность:

> [BOS] Я не сумасшедший

3) Из каких представлений формируются запросы Q, ключи K и значения V в cross-attention?

4) Какая из схем соответствует маске self-attention в decoder при обучении модели? Объясните свой выбор.

